

面向情感变化检测的语音情感数据库

张会云^{1,2,3}, 黄鹤鸣^{1,2,3*}, 李伟^{1,2,3}

(1. 青海师范大学计算机学院, 青海 西宁 810008;

2. 藏文信息处理教育部重点实验室 青海 西宁 810008;

3. 青海省藏文信息处理与机器翻译重点实验室, 青海 西宁 810008)

摘要: 语音情感数据库是进行语音情感识别研究的基础。多样化、大规模、高质量的优质的语音情感数据库对语音情感识别系统性能的提升具有重要作用。研究首先全面地分析了目前国内外使用最广泛的语音情感数据库, 并将其归纳为单模态语音情感数据库和多模态语音情感数据库; 然后通过实验将不同数据库上所取得的最优性能进行对比, 选出可推荐的优质语音情感数据库, 为相关研究人员提供有价值的学术参考; 最后对未来语音情感数据库的建立提出几点建议。

关键词: 语音情感识别; 语音可懂度; 人机交互; 语音情感数据库

中图分类号: TP391.9 **文献标识码:** B

Emotional Change Detection Oriented Speech Emotion Database

ZHANG Hui-yun^{1,2,3}, HUANG He-ming^{1,2,3}, LI Wei^{1,2,3}

(1. School of Computer Science, Qinghai Normal University, Xining Qinghai 810008, China;

2. Key laboratory of Tibetan information processing, Ministry of education, Xining, Qinghai 810008, China;

3. Tibetan information processing and Machine Translation Key Laboratory of Qinghai Province, Xining, Qinghai 810008, China)

ABSTRACT: Speech emotion database is the basis of speech emotion recognition. Diversified, large-scale and high-quality speech emotion database plays an important role in improving the performance of speech emotion recognition system. Firstly, the most widely used speech emotion database at home and abroad was comprehensively analyzed and classified into single mode speech emotion database and multi-mode speech emotion database. Then, through the experiment, the optimal performance of different databases was compared, and the recommended high-quality voice emotion database was selected to provide valuable academic reference for relevant researchers. Finally, some suggestions were put forward for the establishment of future speech emotion database.

KEYWORDS: Speech emotion recognition; Speech intelligibility; Human-machine interaction; Speech emotion database

1 引言

随着语音识别技术的迅速发展,以计算机、手机、平板等为载体的人工智能研究日新月异。各种人机交互不再局限于识别特定说话人语音中的单一音素或语句,如何识别语音中的情感已成为 ASR 领域的新兴研究方向。语音不仅包含说话人所要表达的语义信息,也包含说话人蕴含的情感状

态,对语音情感的有效识别能够提升语音可懂度,使各种智能设备最大限度理解用户意图,达到人性化水平,从而更好地为人类服务。

语音情感识别(Speech Emotion Recognition, SER)指利用计算机分析情感,提取出情感特征值,并用这些参数进行相应建模和识别,建立特征值与情感的映射关系,最终对情感进行分类。语音情感数据库是进行 SER 研究的基础。优质的语音情感数据库对 SER 系统性能的提升具有重要作用,所谓优质是指数据库中的每条语句都能真实确切地表达出说话人的情感状态。因此,多样化、大规模、高质量的语音情感数据库是保证 SER 顺利进行的第一步。

基金项目: 青海省自然科学基金(2016-ZJ-904); 国家自然科学基金(61662062, 61462072)

收稿日期: 2019-11-07 修回日期: 2020-03-02

2 相关工作

SER 系统包括语音情感数据的获取和预处理、语音情感特征提取与选择、声学模型训练以及分类决策 4 个阶段^[1]。语音情感数据库相关内容第 3 部分会详细介绍,下面着重介绍语音情感特征提取与分类算法。

特征提取: SER 是一项有挑战性的任务,对情感的识别依赖于语音情感特征分类的有效性。语音情感特征可分为语言特征和声学特征^[2,3]。语言特征即语音所要表达的言语

信息,声学特征则包含了说话人语气、语调,蕴含感情色彩。提取关联度高的声学特征有助于确定说话人情感状态。通常以帧为单位提取声学特征,并以全局统计方式作为模型输入参与情感识别^[4]。全局统计指听觉上独立的语句或单词,如极值、方差、均值、最小值、最大值、峰度等。常用的声学特征包括韵律特征^[5]、谱特征^[6]和音质特征^[7]。为了进一步提升识别性能,研究者也将基于人耳听觉特性的特征^[8]、非线性动力特征^[9]引入 SER,见表 1。

表 1 基于语音情感的声学特征分类

声学特征	成分
韵律特征	能量、语速、基频、时长、过零率、共振峰
基于谱的特征	线性谱特征和倒谱特征
音质特征	共振峰频率、带宽、频率扰动、振幅扰动、谐波噪声比、闪光以及声门参数
基于人耳听觉特性的特征	过零峰值幅度特征
i - vector 特征	GMM 超向量空间映射到低维总变异空间
非线性特征	最小延迟时间、关联维数、Kolmogorov 熵、最大 Lyapunov 指数和 Hurst 指数
个性化与非个性化特征	个性化特征反映数值大小,非个性化特征反映说话过程中情感的变化情况
融合特征	多声学特征融合

表 1 给出了语音情感特征分类及其所包含的成分。通常来说,单一特征不能完全包含语音情感的所有有用信息,为了使 SER 系统性能达到最优,研究者通常将不同特征融合来提高系统性能。

分类算法: 要对情感状态进行判断,首先要建立 SER 模型。识别模型是 SER 系统的核心。在识别过程中,情感特征输入到识别网络,计算机通过相应算法获取识别结果。常用 SER 分类方法有: 极限学习机(Extreme Learning Machine, ELM)^[10]、动态时间规整(Dynamic Time Warping, DTW)^[11]、高斯混合模型(Gaussian Mixture Model, GMM)^[12]、支持向量机(Support Vector Machine, SVM)^[12,13]、隐马尔科夫模型(Hidden Markov Model, HMM)^[14]及人工神经网络(Artificial Neural Network, ANN)^[15]等。

3 语音情感数据库

人的情感是通过面部表情、身体姿态、声音及生理信号等多种模态表现出来的^[16]。情感判断可基于这些模态中的一个或多个进行,但单模态信息不全面、易受干扰,而多模态信息能够互相印证、互相补充,从而为情感判断提供更全面、准确的信息,最终提高情感识别性能。随着 SER 的发展,各种单模态、多模态语音情感数据库应用而生,根据语音属性将数据库归类,见表 2。

表 2 根据语种差异、语音自然度、情感获取方式及情感描述模型将语音情感数据库归类,通常研究者立足于情感描述模型,即将情感划分为离散型情感和维度型情感进行研究。为了更直观地区分两类情感,表 3 进行了详细总结。

表 2 语音情感数据库归类

语音属性	情感语料库类型
语种差异	中文、英语、德语、法语等
语音自然度	模仿型、诱发型和自然型
情感获取方式	表演型、引导型、启发型和摘引型
情感描述模型	离散型、维度型(连续型)

表 3 两种情感描述模型的区别

考察点	离散情感描述	维度情感描述
描述方式	形容词标签	笛卡尔空间的坐标点
描述能力	有限情感类别	任意情感类别
优点	简单、易懂	无限的情感描述能力
缺点	单一、有限的情感描述能力无法满足对自发情感的描述	将主观情感量化为客观实数值的 过程难以保证质量

由表 3 可知,离散型情感^[17,18]指使用形容词标签将不同情感表示为相对独立的情感类别,多属于表演型或引导型,每类情感演绎逼真,能达到单一、易辨识的程度。维度型情感^[18,19]通过唤醒维(Arousal)、效价维(Valence)、支配维(Dominance)等取值连续的维度将情感描述为一个多维信号,要求标注者将主观情感直接量化为客观实数值,如图 1 所示。其中,Arousal 是对人生理活动/心理警觉水平的度量;效价维度量人的愉悦程度,情感从极度苦恼到极度开心互相转化;支配维指影响周围环境或反过来受其影响的一种感受。为了更完整地描述情感,研究者也将期望维(Expectation)、强度维(Intensity)加入维度描述模型^[16,20]。期望维是




图1 愉悦-唤醒模型^[8]

对说话人情感出现的突然性度量,即说话人缺乏预料和准备程度的度量;强度维指说话人偏离冷静的程度^[8]。

近年来,随着 SER 研究的顺利开展,研究者根据情感描述模型录制了相应的离散型语音情感数据库(见表4)和维度型语音情感数据库(见表5),所列的各类情感数据库大都公开或可以通过许可证授权得到。

由表4可见,大部分数据库都是通过表演方式采集。事实上采用自发语音情感更合理,但使用表演型情感数据库也有一定好处,可避免数据库包含过多无效标签数据。由表5可知,常用的维度型情感语料库主要有: VAM、DEAP、RECOLA、SEMAINE、IEMOCAP 及 CreativeIT,对于维度型情感库通常采用 PAD 量表进行情感信息标注。

表4 常用的离散型语音情感数据库

数据库	语种	获取方式	情感数量	录音人数	语料内容
Belfast	英语	表演型	5	20 男 20 女	5 个段落,每段 7~8 个句子
EMO-DB	德语	表演型	7	5 男 5 女	535 句
AIBO	德语	自然型	11	21 男 30 女	48401 个单词,9.2 小时
CASIA	汉语	表演型	5	2 男 2 女	9600 句
CHEAVD	汉语	表演型	6	238 人	140 分钟
北航库	汉语	表演型	5	4 男 3 女	1140 句
EESDB	普通话	表演型	7	11 人	427 句
DES	丹麦语	表演型	5	4	2 个字,9 段句子,2 篇短文

表5 常用的维度型语音情感数据库

数据库	场景	参与者数	模态	情感维度	标注者数	工具/方法	标签范围与类型
VAM	脱口秀节目	47	Vi + Au	A, V, D	6~34 人	SAM 系统	[-1, 1] 的 5 点等间隔值
DEAP	音乐视频	32	Vi + Ph	A, V, D	1 人	SAM 系统	[-1, 9] 的连续值
RECOLA	视频会议	46	Vi + Au + Ph	A, V	6 人	ANNEMO	[-1, 1] 的连续值
SEMAINE	Solid SAL	24	Vi + Au	A, V, E, D, I	2~8 人	FEELtrace	[-1, 1] 的连续值
IEMOCAP	对话表演	10	Vi + Au	A, V, D	至少 2 人	SAM 系统	1~5 的整数
CreativeIT	对话表演	16	Vi + Au	A, V, D	3~4 人	FEELtrace	[-1, 1] 的连续值

注: Vi—视觉模态,Au—听觉模态,Ph—生理信号,A—唤醒维,V—效价维,E—期望维,D—支配维,I—强度维

3.1 单模态语音情感数据库

1) Belfast 英语情感数据库

Belfast 数据库^[21,22]由 Queen 大学录制,包含 40 位说话人使用 5 类情感(生气/anger、悲伤/sadness、高兴/happiness、恐惧/fear 和中性/neutral)演绎 5 个段落得到的语音。

2) EMO-DB 德语情感数据库

EMO-DB 数据库^[23]是由柏林工业大学在专业录音室录制的,采样率为 48kHz,压缩后 16kHz,16bit 量化。录制时从 40 个说话人中选取 10 位对 10 个德语语句进行情感演绎,包含中性/neutral、生气/anger、恐惧/fear、高兴/joy、悲伤/sadness、厌恶/disgust 和困倦/boredom 等 7 种情感,共 800 句语料,考虑到说话人语音自然度,最终选取 535 个样本,对应样本数量分别为 79、127、69、71、62、46、81。部分文献中,研

究者从 535 条语句中选出了 494 条,用于 SER^[24]。

3) AIBO 自然语音情感数据库

AIBO 数据库^[24]包含了英语和德语两类语音。德语数据库^[24]是由“MONT”、“OHM”两所学校录制的,对应样本数为:8258、9959。该库通过无线耳麦采集了 51 名(MONT 25, OHM 26)10~13 岁的儿童与索尼公司电子宠物狗 Aibo 进行游戏交互时的语音,采样率为 48kHz,压缩后 16kHz,16bit 量化。每条语音都有明显的情感倾向,共 48401 个单词,时长 9.2h,数据库总样本 18216 条,由 5 位语言学专业学生通过投票方式标注情感,当 3 个及以上的标注者判定为同一种情感时投票通过。该库涵盖高兴/joyful、强调/emphatic、中性/neutral、溺爱/motherese、无聊/bored、惊讶/surprised、无助/helpless、易怒/touchy、愤怒/angry、谴责/reprimanding 和含糊/rest 等 11 类情感。目前关于情感标签仍无定论,最常用的标

签方法有 2 种: 5 类情感, 2 类情感。5 类情感包括: Angry(记作 A, 包含 angry, touchy, reprimanding)、Emphatic(记作 E)、Neutral(记作 N)、Positive(记作 P, 包含 motherese, joyful)、Rest(记作 R), 对应样本数分别为 1492、3601、10967、889、1267; 对于 2 类问题, 类别为 Negative(记作 NEG, 包含 angry, touchy, reprimanding, emphatic) 和 Idle(记作 IDL), 样本数分别为 5823 和 12393。该库 33% 的单词被 INTERSPEECH 2009 进行 SER 竞赛所用^[2]。

英文库由 30 个儿童(4 ~ 14 岁) 录制而成, 语音总共 8.5 个小时。

4) CASIA 中文语音情感数据库

CASIA 数据库^[3]是由中科院自动化研究所在干净环境下录制的, 包含 4 位专业发音人在 6 类情感(高兴/happiness、害怕/fear、悲哀/sadness、生气/anger、惊吓/scare 和中性/neutral) 下演绎的 9600 条情感语音。采样率为 16kHz, 16bit 量化。目前公开的 CASIA 库中, 包含 1200 条语音, 每类情感各 200 条语音。

5) 丹麦 DES 情感语料库

DES 数据库^[4]包含两个单词(是, 否), 9 句话和 2 个短句。情感类型有: 高兴/happiness、伤心/sadness、中性/neutral、生气/anger 和惊奇/surprise。通过 20 个年龄在 18 ~ 58 岁的本地人鉴定, 识别率可达 67%。

6) 老人语音情感库 EESDB

EESDB 数据库^[5]语音数据来自《老人的故事》。该库录制了 11 位说话人(6 男 5 女) 演绎的 7 类情感(高兴/happy、伤心/sad、中性/neutral、生气/angry、害怕/fear、惊奇/surprise、厌恶/disgust), 共 992 条语音, 采样率 44kHz, 16bit 量化。选取 8 位评估者对语音情感进行判定, 若 75% 的评估者同时判定为相同情感则对其保留, 最终保留了 427 条情感语音。

7) 北京航空航天大学情感语料库

北京航空航天大学情感语料库是一个中文数据库^[6], 录制了 7 位说话人(4 男 3 女) 在 20 个文本下演绎的 5 类情感(愤怒/anger、高兴/happiness、悲伤/sadness、厌恶/disgust、惊讶/surprise), 每个文本在相同情感下重复 3 次, 经评估后, 最终保留 1140 条情感语音。

8) Semaine 数据库

Semaine^[7]是一个面向 AI 与人机交互的数据库, 可免费用于科学研究。该库是在专业录音室环境下进行人机交互录制的, 录制时, 20 位说话人被要求与 4 位个性不同的(温和而智慧的/Prudence、快乐而外向的/Poppy、悲伤而抑郁的/Obadiah 和怒气冲冲的/Spike) 虚拟人物(由工作人员扮演) 进行语音对话, 该虚拟人物不仅能理解说话人表达的语义信息, 与用户也有情感交流, 录音长达 7 小时。由 5 个高帧频、高分辨率摄像机和 4 个麦克风共同采集数据, 采样率为 48kHz, 24bit 量化。最后, 在 valence、activation、power、intensity 和 expectation 等 5 个维度上进行标注。

9) TYUT2.0 中文情感语音数据库

TYUT2.0 数据库^[8]是通过截取广播剧的方式获得的一种摘引型情感数据库, 使用 PAD(Pleasure - Arousal - Dominance) 情感量表对语音情感进行维度标注。在标注试验中, 招募 100 名在校学生(44 男 56 女) 对 3 类情感(高兴/pleasure、悲伤/sadness、愤怒/anger) 共 161 个语音样本按照范围为 1 ~ 5 的 PAD 量表进行维度标注, 得到 161 × 100 维的数据样本, 每个语音样本维度值取所有标注值的平均。

10) SUSAS 英语情感数据库

SUSAS 数据库^[9,33]录制了 7 位说话人(4 男 3 女) 的 3593 条情感语音, 主要用于分析压力级别, 压力类别包括高压/high stress(hist)、中压/medium stress(med)、中性/neutral (neut)、强压/screaming(scre), 对应类别样本数分别为 1202、1276、701 和 414。在 Arousal 维上 neut 为正, 其它为负; 在 Valence 上 neut、scre 为正, 其它为负。

3.2 多模态语音情感数据库

1) IEMOCAP 英语情感数据库

IEMOCAP 数据库^[6]是由美国南加州大学录制的, 由 10 名演员(5 男 5 女) 在有剧本或即兴场景下诱发特定情感, 包含音频、文本、面部表情以及视频。整个数据集划分为 5 部分, 每部分均由 1 男 1 女表演组成。离散型和维度型情感标注都被应用于该数据库。离散型情感标签分为中性/neutral、高兴/happiness、生气/anger 和悲伤/sadness 等, 每类对应样本数量为: 1708、1636、1103 和 1084, 总计 5531 句(其中即兴表演包含 2280 句), 时长约 12 小时。此外, IEMOCAP 数据库也采用了 valence、activation 和 dominance 维度空间模型进行标注, 维度幅值范围为 [-1, 5]。

2) RECOLA 数据库

RECOLA 数据库^[7]录制了 46 位说话人(两人 1 组被分成 23 组, 每组通过远程视频会议讨论某个灾难场景下逃生方案) 的语音情感数据。数据中包含所有说话人在讨论过程中的面部视频和音频以及其中 35 个说话人的 ECG、EDA 数据。标注人员按照视频帧率逐帧给出了说话人前 5 分钟讨论过程中情感状态在 valence 和 Arousal 的值。

3) eINTERFACE'05 英语情感数据库

eINTERFACE'05 数据库^[8]是基于面部表情和语音的双模态情感数据库, 录制条件为办公室环境, 带有一定回声, 录制文本来自于故事, 所有录制人员通过听取 6 个短片小故事, 得到一种情感, 通过两名专家最终确定语音是否符合要求。数据库采集了来自 14 个国家 42 位说话人(34 男 8 女) 的 6 类基本情感(生气/anger、厌恶/disgust、害怕/fear、开心/happy、伤心/sadness、惊讶/surprise), 每类情感对应样本数量为: 200、189、187、205、195 和 190。样本采用分辨率为 80 万像素的微型 DV 数字摄像机以 25 帧/秒的速度摄制, 利用专用的高质量麦克风以 16bit 格式记录 48kHz 的未压缩立体音频信号, 每个图片帧大小为 720* 576。

4) RML 数据库

RML 数据库^[9]是基于面部表情和语音的双模态公开情

感数据库,由加拿大 Ryerson 多媒体实验室录制,录制环境较为明亮,无嘈杂的背景音。采样率为 44kHz,16bit 量化。视频样本包含 8 位说话人表达的 6 类基本情感(生气/anger、厌恶/disgust、害怕/fear、开心/happy、伤心/sadness、惊讶/surprise),共 720 个语音和人脸情感。视频帧率为 30 帧/s,尺寸为 720* 480。每个视频持续时间为 3~6s。

5) AFEW6.0 数据库

AFEW6.0^[64]并非是在实验室环境下建立的传统数据库,它是 Emotion Recognition in the Wild(EmotiW) 2016 challenge 比赛提供的官方数据库,库中所有样本均为电影或电视剧剪辑片段且混有复杂的背景信息。该库中的视频样本包含 7 类情感,被划分为训练集(773 个)、验证集(383 个)和测试集(593 个),训练集和验证集公开,测试集用于比赛评定,非公开。

6) GEMEP 数据库

GEMEP 数据库^[61]包含语音样本集及其对应的视频样本集 GEMEP-FERA^[62],应用于 INTERSPEECH 2013 Challenge^[63]。数据库包含 10 位说话人(5 男 5 女)的 1260 个样本,共 18 个情感类别(羡慕/admiration、愉悦/amusement、焦虑/anxiety、冷漠/cold anger、蔑视/contempt、绝望/despair、厌恶/disgust、兴高采烈/elation、暴怒/hot anger、兴趣/interest、恐慌/panic、恐惧/fear、乐意/easure、骄傲/pride、宽慰/relief、悲伤/sadness、羞愧/shame、惊讶/surprise、温柔/tenderness)。常用的情感有 12 类,平均每类约 90 个样本,共 1080 个样本。

7) ABC 德语情感数据库

ABC 双模态数据库^[64]模拟了不同情境下公共交通中说话人的情感,是一个诱发数据库,含 8 位说话人(4 男 4 女,25~48 岁)的 430 条视频情感语音,时长 11.5 个小时,由 3 名专家对数据进行剪辑,标定情感。其情感类别为:挑衅/aggressive、愉快/cheerful、陶醉/intoxicated、紧张/nervous、中性/neutral、疲倦/tired,对应样本数为 95、105、33、93、79、25。

8) ACCorpus 系列中文情感数据库

ACCorpus 数据库^[63]是由清华大学和中科院心理研究所合作录制,录音人数较多,是一个很全面、很系统、有代表性的数据库,采样率 16kHz,16bit 量化。包含 5 个子库,分别是:ACCorpus_MM 多模态、多通道情感数据库、ACCorpus_SA 汉语普通话情感分析数据库、ACCorpus_FV 人脸表情视频数据库、ACCorpus_FI 人脸表情图像数据库、ACCorpus_SR 情感语音识别数据库。其中,ACCorpus_SR 库录制了 50 位(25 男 25 女)说话人在 5 类情感状态(中性/neutral、高兴/happiness、生气/anger、恐惧/fear 和悲伤/sadness)下的语音。

9) AVEC 2012 数据库

AVEC 2012^[63]是包含语音和视频的多模态情感数据库,来源于 Semaine 数据库中 Solid-SAL 的 24 条情感记录文件。曾用于 2012 年音/视频情感识别挑战大赛,被分为训练集、验证集和测试集。数据时长在 7 小时左右,标注工作由 3~8 个评估者借助标注工具 FEELTRACE 在 Valence、Activation、

Power 和 Expectation 四个情感维度上标注。

10) VAM 德语情感数据库

VAM 数据库^[64]是对德语电视谈话节目“Vera am Mittag”进行现场录制而成的,包括表情库、视频库、语音库 3 部分。语音库包含 47 位嘉宾 947 句语音,采样率为 16kHz,16bit 量化。在 valence、activation 和 dominance 维度上标注,标注值在 [-1, 1]。

11) AVIC 英语情感数据库

AVIC 数据库^[67]是一种双模态情感库,录制了 21 位(男 11 女 10)产品推销员使用英语进行商业推广的语音和面部表情。样本情感类别为:无聊/boredom、中性/neutral、高兴/joyful,每类情感对应样本数量为 553、2279、170,共 3002 个样本。

12) MOUD 西班牙语情感数据库

MOUD 模态数据库^[68]采集了 80 位说话人(65 男 15 女)的文本、语音和视频信息,共 498 个样本。其中样本情感标注分为 3 类:积极/positive、中立/neutral 和消极/negative,每类样本对应数量为:182、85、231。

13) MOSI 英语数据库

MOSI 是 2016 年 Zadeh 团队开发出来的较大的一个多模态情感数据库^[69],共采集了 89 位说话人(48 男 41 女)的文本、语音和视频 3 个模态的信息,共 2199 个样本,说话人年龄主要集中在 20~30 岁。

14) SAVEE 语音情感数据库

SAVEE 模态数据库^[64]是由 4 名演员在 7 种情感状态(生气/anger、厌恶/disgust、害怕/fear、高兴/happiness、中性/neutral、伤心/sadness 以及惊讶/surprise)下演绎得到的表演型数据库,共 480 条情感,语音情感数量分布相对平衡,除中性(120 条)外,其余 6 类情感均有 60 条。

15) CHEVAD 中文自然情感数据库

CHEVAD 数据库^[61]是由中科院自动化研究所录制的,也是中科院自动化所举办的 2017 多模态情感识别竞赛的官方数据集,数据来自中文电影、电视剧及脱口秀节目,时长 140 分钟,说话人数达到 238 人,年龄范围从儿童到老人。由 4 名中国人标注数据,总共 26 个非原型情感状态,包含了常用的 6 类情感状态(愤怒/anger、恐惧/fear、高兴/happy、中性/neutral、悲伤/sad 和惊讶/surprise),训练集、验证集和测试集中情感语音数量分别为:4917、707 和 1406。

16) DEAP 数据库

DEAP 数据库^[63]录制了 32 位说话人观看音乐视频时的 EEG 信号、外围生理信号及其中 22 位说话人的正面视频。每个说话人都观看了 40 段音乐视频,并将自己在观看过程中所感受到的情感在唤醒维、效价维和支配维上给出了 [1, 9] 的连续自我评估。

4 实验

下面以 SAVEE、RML、eNTERFACE05 模态数据库为例,

分析在不同数据库上使用不同分类方法所取得的最佳性能。

表 6 展示了 2015 ~ 2019 年在 SAVEE 数据库上使用不同分类方法所取得的性能。由表 6 可知,在 SAVEE 数据库上,目前结合多模态信息的 SER 系统最优性能可达到 98.33%,这是一个非常客观的结果。

表 6 SAVEE 多模态库上不同方法性能比较

Work	Accuracy(%)
文献 [53] (2015)	96.20
文献 [54] (2015)	98.00
文献 [55] (2017)	52.86
文献 [56] (2019)	98.33

表 7 展示了 2012 ~ 2019 年不同研究者在 RML 模态数据库上的研究结果。由表 7 可知,目前 RML 数据库上各分类方法整体性能不是很好,2015 年取得的最优性能为 83%。

表 7 RML 多模态库上不同方法的性能比较

Work	Accuracy(%)
文献 [57] (2012)	71.00
文献 [58] (2015)	83.00
文献 [59] (2016)	79.00
文献 [55] (2017)	72.92
文献 [56] (2019)	73.12

表 8 展示了 2009 ~ 2019 年部分研究者在 eINTERFACE05 模态数据库上的实验结果。由表 8 可知,文献 [58] 取得了最优的性能,其它各类方法的性能均较低。纵观表 6、表 7、表 8,可以得出:在 SAVEE 数据库上目前各分类方法取得了最优性能,RML 次之,eINTERFACE05 数据库上性能最差。归因于 eINTERFACE05 库带有一定噪音,而 RML 模态数据库中的语料较为干净,SAVEE 数据库是由专业演员录制的,对于每种情感的表达到位,数据库质量较好。

表 8 eINTERFACE05 多模态库上不同方法的性能比较

Work	Accuracy(%)
文献 [60] (2009)	37.71
文献 [61] (2010)	28.00
文献 [62] (2010)	37.00
文献 [63] (2010)	54.70
文献 [64] (2011)	46.78
文献 [57] (2012)	58.00
文献 [65] (2013)	52.80
文献 [66] (2013)	56.40
文献 [67] (2014)	38.20
文献 [59] (2016)	83.00
文献 [55] (2017)	40.05
文献 [56] (2019)	62.80

5 结论与展望

目前 SER 使用的数据库逐渐从表演型情感语料库向自然型情感语料库过渡,为了进一步提升 SER 的性能,研究者开始将多模态信息引入 SER,通过将面部表情、文本信息、手语、生理信号等多模态信息与语音信息相结合以进一步提升性能。目前研究者聚焦在多模态数据库上进行研究,SAVEE、RML、eINTERFACE05 是研究者常用的模态数据库。作者目前立足于藏语 SER,为了确保其性能良好,应在干净环境下录制高质量、大规模的模态藏语情感库。

参考文献:

- [1] 詹永照,毛启荣,林庆,等. 视觉语音情感识别 [M]. 北京: 科学出版社, 2019: 9 - 17.
- [2] M Seyedmahdad, B Emad, Z Cha. Automatic speech emotion recognition using recurrent neural networks with local attention [C]. IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). New Orleans, USA. 2017: 2227-2231.
- [3] F Tao, G Liu. Advanced LSTM: A study about better time dependency modeling in emotion recognition [C]. IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). Calgary, Canada. 2018: 2906 - 2910.
- [4] B Rainer, R Klaus. Acoustic profiles in vocal emotion expression [J]. Journal of Personality and Social Psychology, 1996, 70(3): 614 - 636.
- [5] J Benesty, M M Sondhi Y. Huang. Springer Handbook on Speech Processing [M]. Berlin: Springer - Verlag, 2008: 11 - 19.
- [6] C Gobl, A N Chasaide. The role of voice quality in communicating emotion, mood and attitude [J]. Speech Communication, 2003, 40 (1/2): 189 - 212.
- [7] Y Sun, X Y Zhang. Study for classification of emotional speech by using optimized frame zero crossing with peak amplitudes feature extraction algorithm [J]. Journal of Computational Information Systems, 2011, 7(10): 3508 - 3515.
- [8] 姚慧,孙颖,张雪英. 情感语音的非线性动力学特征 [J]. 西南电子科技大学(自然科学版), 2016, 43(5): 162 - 172.
- [9] G E Hinton, S Osindero. A fast learning algorithm for deep belief nets [J]. Neural Computation, 2006, 18(7): 1527.
- [10] 张雪英,孙颖,张卫,等. 语音情感识别的关键技术 [J]. 太原理工大学学报, 2015, 46(6): 629 - 636, 643.
- [11] N Vlassis, A Likas. A greedy em algorithm for Gaussian mixture learning [J]. Neural Processing Letters, 2012, 15(1): 77 - 87.
- [12] A Hassan, R I Damper. Multi - class and hierarchical SVMs for emotion recognition [C]. International Speech Communication Association. Chiba, Japan. 2010: 2354 - 2357.
- [13] 赵涓涓,马瑞良. 基于决策树和改进 SVM 混合模型的语音情感识别 [J]. 北京理工大学学报, 2017, 37(4): 386 - 395.
- [14] H Gunes, B Schuller. Categorical and dimensional affect analysis in continuous input: current trends and future directions [J]. Im-

- age and Vision Computing, 2013,31(2): 120 – 136.
- [15] 曾毅,刘成林,谭铁牛. 类脑智能研究的回顾与展望 [J]. 计算机学报, 2016,39(1): 212 – 222.
- [16] 李霞,卢官明,闫静杰,等. 多模态维度情感预测综述 [J]. 自动化学报, 2018,44(12): 2142 – 2159.
- [17] 乐国安,董颖红. 情绪的基本结构: 争论、应用及其前瞻 [J]. 南开学报(哲学社会科学版), 2013,(1): 140 – 150.
- [18] 韩文静,李海峰,阮华斌,等. 语音情感识别研究进展综述 [J]. 软件学报, 2014,25(1): 37 – 50.
- [19] S Arifin, P Y K Cheung. Affective level video segmentation by utilizing the pleasure – arousal – dominance information [J]. IEEE Transactions on Multimedia, 2008,10(7): 1325 – 1341.
- [20] H Gunes, B Schuller. Categorical and dimensional affect analysis in continuous input: Current trends and future directions [J]. Image and Visual Computing, 2013,31(2): 120 – 136.
- [21] R Cowie, E D Cowie, S Savvidou, et al. ‘FEELTRACE’: An Instrument for Recording Perceived Emotion in Real Time [C]. ISCA Workshop on Speech and Emotion. Belfast, England. 2000.
- [22] S McGilloway, R Cowie, E D Cowie, et al. Approaching automatic recognition of emotion from voice: A rough benchmark [J]. ResearchGate, 2000.
- [23] F Burkhardt, A Paeschke, M Rolfes, et al. A database of German emotional speech [C]. INTERSPEECH 2005-Eurospeech, European Conference on Speech Communication and Technology. Lisboa, Portugal. 2005: 1517 – 1520.
- [24] Y Jin, P Song, W Zheng, et al. Speaker – independent speech emotion recognition based on two – layer multiple kernel learning [J]. IEICE Transactions on Information and Systems, 2013, E96 – D(10): 2286 – 2289.
- [25] A Atliner, C Hacker, S Steidl, et al. “You stupid tin box” Children interacting with the AIBO robot: A cross – lingual emotional speech corpus [C]. 4th Interactional Conference on Language Resources and Evaluation. Lisbon, Portuguesa, 2004: 171 – 174.
- [26] S Steidl. Automatic classification of emotion – related user states in spontaneous children’s speech [M]. Germany: University of Erlangen – Nuremberg, 2009: 50 – 53.
- [27] B Schuller, S Steidl, A Batliner. The INTERSPEECH 2009 emotion challenge [C]. Annual Conference of the International Speech Communication Association. Brighton, United Kingdom. 2009: 312 – 315.
- [28] J H Tao, F Z Liu, M Zhang, et al. Design of speech corpus for mandarin text to speech [C]. Blizzard Challenge Workshop. Brisbane, Australia. 2008.
- [29] I Engberg, A Hansen. Documentation of the Danish emotional speech database [J]. Denmark: Aalborg University, 1996.
- [30] K X Wang, Q L Zhang, S Y Liao. A database of elderly emotional speech [C]. International Symposium. Signal Process. Biomed. Eng Informat. 2014: 549 – 553.
- [31] L Fu, X Mao, L Chen. Speaker independent emotion recognition based on SVM/HMMs fusion system [C]. International Conference on Audio, Language and Image Processing. Shanghai, China, 2008: 61 – 65.
- [32] Anonymous. Semaine Internationale DE LA Technologie Textile [J]. Textile: Canadian Textile Journal. 2009,126(2).
- [33] F Cid. A novel multimodal emotion recognition approach for affective human robot interaction [C]. FinE, 2015: 1 – 9.
- [34] 张雪英,张婷,孙颖,等. 情感语音数据库优化及 PAD 情感模型量化标注 [J]. 太原理工大学学报, 2017,48(3): 469 – 474.
- [35] J Hansen, S Bou – Ghazale, R Sarikaya, et al. Getting started with SUSAS: A speech under simulated and actual stress database [C]. European Conference on Speech Communication and Technology. Rhodes, Greece. 1997: 1743 – 1746.
- [36] B Schuller, B Vlasenko, F Eyben, et al. Acoustic emotion recognition: A benchmark comparison of performances [C]. IEEE Workshop on Automatic Speech Recognition and Understanding (ASRU). Merano, Italy. 2009: 552 – 557.
- [37] B Carlos, B Murtaza, C C Lee, et al. IEMOCAP: Interactive emotional dyadic motion capture database [J]. Language Resources and Evaluation, 2008,42(4): 335 – 359.
- [38] F Ringeval, A Sonderegger, J Auer, et al. Introducing the RECOLA multimodal corpus of remote collaborative and affective interactions [C]. IEEE International Conference and Workshops on Automatic Face and Gesture Recognition. Shanghai, China. 2013: 1 – 8.
- [39] O Martin, I Kotsia, B Macq, et al. The eNTERFACE’05 audio – visual emotion database [C]. 22nd International Conference on Data Engineering Workshops. Atlanta, USA. 2006: 1 – 8.
- [40] Y Wang, L Guan. Recognizing human emotional state from audio-visual signals [J]. IEEE Transactions on Multimedia, 2008,10(5): 936 – 946.
- [41] A Dhall, R Goecke, J Joshi, et al. EmotiW 2016: video and group – level emotion recognition challenges [C]. ACM International Conference on Multimodal International(ICMI). Tokyo, Japan. 2016: 427 – 432.
- [42] T Banziger, M Mortillaro, K R Scherer. Introducing the Geneva Multimodal expression corpus for experimental research on emotion perception. Emotion [J], 2012,12(5): 1161.
- [43] A Dhall, A Asthana, R Goecke, et al. Emotion recognition using PHOG and LPQ features [C]. IEEE International Conference on Automatic Face and Gesture Recognition and Workshop(FG). Aalborg, Denmark. 2001: 2679 – 2682.
- [44] B Schuller, S Steidl, A Batliner, et al. The INTERSPEECH 2013 computational paralinguistics challenge: Social signals, conflict, emotion, autism [C]. Annual Conference of the International Speech Communication Association. Lyon, France. 2013.
- [45] B Schuller, D Arsic, G Rigoll, et al. Audio – visual behavior modeling by combined feature spaces [C]. IEEE International Conference on Acoustics, Speech and Signal Processing(IC-ASSP). Honolulu, USA. 2007: II – 733.
- [46] B Schuller, M Valster, F Eyben, et al. AVEC 2012: the continu-

- ous audio/visual emotion challenge [C]. 14th ACM international conference on Multimodal interaction (ICMI). Santa Monica, USA, 2012: 449 – 456.
- [47] M Grimm, K Kroschel, S Narayanan. The Vera am Mittag German audio – visual emotional speech database [C]. IEEE International Conference on Multimedia and Expo(ICME). Hannover, Germany. 2008: 865 – 868.
- [48] B Schuller, R Müller, F Eyben, et al. Being bored? Recognising natural interest by extensive audiovisual integration for real – life application [J]. Image and Vision Computing, 2009, 27(12): 1760 – 1774.
- [49] V Pérez – Rosas, R Mihalcea, L P Morency. Utterance – level multimodal sentiment analysis [C]. 51st Annual Meeting of the Association for Computational Linguistics(ACL). Sofia, Bulgaria. 2013: 973 – 982.
- [50] A Zadeh, R Zellers, E Pincus, et al. MOSI: Multimodal Corpus of Sentiment Intensity and Subjectivity Analysis in Online Opinion Videos [J]. IEEE Intelligent Systems, 2016, 31(6): 82 – 88.
- [51] H Sanaul, P Jackson. Speaker – dependent audio – visual emotion recognition [C]. International Conference on audio – visual speech processing. 2009: 53 – 58.
- [52] Y. Li, J. H Tao, L. Chao, et al. CHEAVD: A Chinese natural emotional audio – visual database [J]. Journal of Ambient Intelligence and Humanized Computing, 2017, 8(6): 913-924.
- [53] S Koelstra, C Mühl, M Soleymani, et al. DEAP: A database for emotion analysis using physiological signals [J]. IEEE Transactions on Affective Computing, 2012, 3(1): 18 – 31.
- [54] S Haq. Bimodal human emotion classification in the speaker – dependent scenario [R]. Proceedings of the Pakistan Academy of Sciences, January, 2015, 52(1): 27 – 38.
- [55] F Noroozi. Audio – visual emotion recognition in video clips [J]. IEEE Transaction Affect Computing, 2017.
- [56] F Rahdari, E Rashedi, M Eftekhari. A multimodal emotion recognition system using facial landmark [J]. Iranian Journal of Science and Technology, Transactions of Electrical Engineering, 2019, 43(1): 171 – 189.
- [57] Y Wang, et al. Kernel cross – modal factor analysis for information fusion with application to bimodal emotion recognition [J]. IEEE Transactions Multimed, 2012, 14(3): 597 – 607.
- [58] C Fadil, et al. Multimodal emotion recognition using deep networks [C]. VI Latin American congress on biomedical engineering. Parana, Argentina. 2014: 29 – 31.
- [59] K Seng. A combined rule – based and machine learning audio – visual emotion recognition approach [J]. IEEE Transactions Affect Computing, 2016, 9(1): 3 – 13.
- [60] D Datcu, L Rothkrantz. Multimodal recognition of emotions in car environments [C]. DCI&I, 2009.
- [61] M Paleari, et al. Towards multimodal emotion recognition: a new approach [C]. ACM International Conference on Image and video retrieval. 2010.
- [62] M Mansoorizadeh, N M Charkari. Multimodal information fusion application to human emotion recognition from face and speech [J]. Multimed Tools Appl, 2010, 49(2): 277 – 297.
- [63] V Struc, F Mihelic. Multimodal emotion recognition using canonical correlations and acoustic features [C]. 20th International Conference on Pattern Recognition(ICPR). 2010.
- [64] D Jiang. Audio visual emotion recognition based on triplestream dynamic Bayesian network models [C]. International Conference on affective computing and intelligent interaction. Springer, Berlin. 2011.
- [65] S Dobrsek, et al. Towards efficient multimodal emotion recognition [J]. Int J Adv Rob Syst, 2013, 10(1): 53.
- [66] K C Huang, H Y S Lin, J C Chan, et al. Learning collaborative decision – making parameters for multimodal emotion recognition [C]. IEEE International Conference on multimedia and expo(ICME). 2013.
- [67] S Zhalehpour, Z Akhtar, C E Erdem. Multimodal emotion recognition with automatic peak frame selection [C]. IEEE International Symposium on innovations in Telligent Systems and Applications (INISTA). 2014.

作者简介



张会云(1993 –), 女(汉族), 甘肃省庆阳市人, 硕士研究生, 主要研究领域为模式识别与智能系统。

黄鹤鸣(1969 –), 男(藏族), 青海省乐都人, 教授, 博士研究生导师, 主要研究领域为模式识别与智能系统。

李 伟(1986 –), 女(汉族), 山东省潍坊市人, 博士研究生, 主要研究领域为模式识别与智能系统。