

文章编号:1001-4098(2010)07-0066-08

面向突发事件的群体情绪监控预警^{*}

刘志明, 刘 鲁

(北京航空航天大学 经济管理学院, 北京 100191)

摘 要:突发事件所引发的群体情绪可能会导致衍生群体事件的发生,所以有必要对群体情绪演化进行监控预警。本文对突发事件发生、发展过程中群体情绪的演化进行了研究,建立了面向突发事件的情绪层次模型以及情绪监控预警模型。通过支持向量机、贝叶斯文本分类算法、 n 元语言模型三种机器学习算法,以及CHI(卡方检验)、DF(文档频率)、IG(信息增益)三种特征选择方法对突发事件相关的微博评论进行了情绪分类的实验分析,实验结果表明支持向量机、IG取得的分类性能最优,得到的分类结果可以满足实际应用的需求。进而对王家岭矿难、山西疫苗两个突发事件进行了实际案例研究,建立并分析了情绪层次演化曲线。最后提出了群体情绪演化预警指标以及预警模式的概念。

关键词:情绪监控;情绪监控预警模型;机器学习方法;预警指标

中图分类号:TP399 **文献标识码:**A

1 引言

随着互联网在我国快速发展,网民数量也急剧增加,根据CNNIC(<http://research.cnnic.cn/>) 2009年的统计,我国网民数量已经达到3.8亿。各种新兴的互联网应用,比如BBS、论坛、博客以及刚刚兴起的微博已经成为网民表达情绪、思想交流的重要舆论渠道,特别是对于突发事件网民所表达的态度、意见和情绪形成迅速、反映强烈,对社会影响巨大,互联网已经成为思想文化信息的集散地和社会舆论的放大器。

突发事件对于社会的影响是巨大的,带来的破坏性是多维度的,其中包括生命损伤、财产损失、社会损伤等维度。前三个维度可以通过定量的方法来统计,而社会损伤主要是对于心理的损伤,这包括突发事件带来的悲伤、气愤、恐慌等负面的情绪,给个人以及社会带来了巨大的破坏。比如汶川地震发生后,网络上弥漫着不同的情绪,对遇难同胞的哀悼与悲伤,对相关问题的质疑,中国网民数量庞大,这种群体性的情绪常常会对政治的稳定和社会的和谐造成很大的危害,甚至会导致新的突发事件发生,及时了解大众的群体情绪态势对于了解当前事件的影响以及监控预警衍生事件的发生具有重要的意义^[1]。

在已有的研究中,王飞跃分析了万维社会媒体在防灾应急中的作用^[2],并且对新闻、博客中网民在汶川地震中的不同情绪变化进行了分析,但没有给出详细的情绪分析的方法,分析的数据来源是新闻和博客。Minglu Li等建立了一个基于web挖掘的大众恐慌监控预警模型^[3],他们主要的研究渠道是BBS,通过考虑帖子的基本影响力、帖子的影响因素、帖子的态度因素来定义帖子的恐慌度,以对突发事件中大众的恐慌程度进行监控预警,文中建立的恐慌指标虽然考虑了人们的情感因素,但对不同的负面情绪没有进行区分。与本研究密切相关的是网络舆情监控预警研究,网络舆情监控是指通过互联网信息采集技术及信息智能处理技术对互联网海量信息自动抓取、分类聚类、主题检测,实现用户的网络舆情监测,为客户全面掌握群众思想动态,做出正确舆论引导,提供分析依据。文献[4]、文献[5]对网络舆情的监控预警指标进行了研究,但是预警指标都是基于评论规模定义的,而对评论本身所含的情绪因素关注不足。

随着网络技术的发展,出现越来越多的渠道可以发表评论,其中包括BBS、即时通讯软件、社交网络以及博客等渠道。在已有的研究中,研究者对不同的渠道进行了研究,其中文献[2]对新闻和博客中的情绪变化进行了研究,文

^{*} 收稿日期:2010-05-28

基金项目:国家自然科学基金资助项目(90924020);教育部博士点基金资助项目(200800060005)

作者简介:刘志明(1979-),男,山东潍坊人,北京航空航天大学博士研究生。

通讯作者:刘鲁(1947-),女,北京航空航天大学教授,博士生导师。

献^[3]以BBS上的帖子为研究对象定义了应急管理中大
众恐慌的监控预警指标。而微博作为一种新兴的信息发布、
交流平台,还没有得到充分的研究。微博是博客的一种形
式,相比于其他的网上信息传播渠道微博具有以下几个特
点:①实时性:发布微博的渠道多种多样,网民可以通过手
机、客户端、插件多种形式发布信息,所以微博的实时性相
比于传统的网络渠道更强,这对于时间要求更高的应用来
说无疑是一个更有价值的信息来源,比如在玉树地震发生
时,震区的网友在第一时间将地震的相关信息发布到了新
浪微博,在救援过程中网友通过微博及时的将灾区所需物
资信息进行发布,对合理的救援捐助提供了有用的信息;
②数据获取相对更加容易,当前大部分微博都提供API,
通过手机、客户端可以很方便的跟踪相关事件的进展;③
长度:微博的长度限制在140个字符,因为长度有限制,评
论所包含的观点也更容易理解。

基于以上分析,本文将微博作为信息来源研究了突发
事件中大众情绪的监控预警问题。首先针对突发事件建立
了情绪层次模型以及情绪监控预警模型。然后使用机器学
习方法对微博评论的情绪分类进行了研究,比较了三种机
器学习算法以及三种特征选择方法在微博情绪分类上的
性能,通过案例分析对两个实际的突发事件建立了情绪演
化曲线。最后提出了群体情绪演化预警指标以及预警模式
的概念。

2 相关知识介绍

2.1 分类方法

(1) 支持向量机分类算法

支持向量机分类方法(SVMs)是基于结构风险最小
化原理的一种新颖的机器学习算法^[7],已经被广泛应用于
文本分类以及人脸识别等领域。在文本分类领域,SVM
被证明是非常高效的,与传统的方法相比SVM鲁棒性更
好^[8]。

本文使用LIBLINEAR用于分类模型的训练及测试,
LIBLINEAR是Rong-En Fan^[9]提出的用于大规模线性文
本分类的一种SVMs算法,对于高维稀疏数据集特别有
效。

(2) 贝叶斯分类算法

贝叶树文本分类算法(Naive Bayes)是经常被使用的
一种文本分类方法,Naive Bayes利用贝叶斯定理来预测
一个未知类别的样本的可能属性,选择其可能性最大的类
别作为样本的类别。模型虽然简单,但是在文本分类领域
应用非常广泛^[10]。

当前有大量的学者使用多项式模型进行文本分类的
研究^[11-12],所以本文也选取多项式贝叶斯分类算法进行
实验。

多项式贝叶斯分类模型通过式(1)计算给定类 c_i 词 w

出现的概率:

$$p(w_t | c_j) = \frac{\sum_{i=1}^{N_j} n_{it}}{\sum_{s=1}^W \sum_{i=1}^{N_j} n_{is}} \quad (1)$$

其中, n_{it} 表示文档 i 中词 t 出现的次数, N_j 表示类别 c_j 的
训练集的大小, W 表示词典大小。

后验概率通过式(2)计算:

$$p(c_j | d_i) = \frac{p(c_j) p(d_i | c_j)}{p(d_i)} \quad (2)$$

(3) n 元语言模型

使用 n 元语言模型进行文本分类是自然语言处理中
的一个新的模型^[13],与传统的向量空间模型不同, n 元
语言模型把文档看作是词的序列,这样词的出现与否可以
看成是一种语言结合模式,使用这些结合模式可以用来对文
档进行分类。

对于一个字符串 $s = c_1 c_2 \cdots c_{n-1} c_n$, n 元语言模型假
设认为第 n 个字符出现的概率只与前 $n-1$ 个字符有关,即:

$$p(c_n | c_1 \cdots c_{n-1}) = p(c_n | c_1 \cdots c_{n-1}) \quad (3)$$

2.2 特征选择方法

(1) 信息增益(IG)

信息增益方法是文本分类中经常使用的一种特征选
取方法^[14],对于特征 t ,通过测量加入特征 t 相对于去掉特
征 t 对分类性能的影响来衡量特征 t 的分类能力。信息增
益公式如下:

$$IG(t) = - \sum_{i=1}^{|C|} P(c_i) \log P(c_i) + P(t) \sum_{i=1}^{|C|} P(c_i | t) P(c_i | \bar{t}) \\ + P(\bar{t}) \sum_{i=1}^{|C|} P(c_i | \bar{t}) \log P(c_i | \bar{t}) \quad (4)$$

其中, $P(c_i)$ 表示类别 c_i 的概率; $P(t)$ 表示特征 t 出现的
概率; $P(\bar{t})$ 表示特征 t 不出现的概率。

(2) CHI统计

CHI统计的方法通过测量特征与类别之间的依赖性
进行特征的选取,CHI值越大意味着特征与类别之间的依
赖性更强,相反CHI值越小意味特征与类别之间相对独
立。CHI值的计算公式如下:

$$CHI(t, c_i) = \frac{N(N_{11}N_{00} - N_{10}N_{01})^2}{(N_{11} + N_{01})(N_{11} + N_{10})(N_{10} + N_{00})(N_{01} + N_{00})} \quad (5)$$

$$CHI(t) = \max_i (CHI(t, c_i)) \quad (6)$$

其中, N 表示训练集中文档总数; N_{11} 表示特征 t 与类别 c_i
同时出现的次数; N_{10} 表示包含特征 t 并且类别不是 c_i 的文
档数; N_{01} 表示类别为 c_i 但不包含特征 t 的文档数; N_{00} 表
示类别不是 c_i 并且不包含特征 t 的文档数。

(3) 文档频率(DF)

文档频率是指包含某个特征的文档数量,文档频率

特征选取方法认为,文档频率太低或者太高的特征对文本的分类作用都不大,因此可以删去这些特征。虽然简单,但是DF方法在中文分类以及英文分类中都有较好的性能^[15]。

3 面向突发事件的情绪监控预警框架

3.1 面向突发事件的情绪层次模型

曾大军等认为个体行为组成的群体行为有着很强的模式,从网络上涌现的海量个体信息中发现群体行为规律,估计当前状态下社会事件的发展态势,对其进一步的发展过程进行预测,可以实现对社会事件高效的辅助决策^[1]。在突发事件发生、发展过程中,大众表现出来的不同情绪混合在一起,分析单个人的情绪也许没有实际意义,但大众所表现出来的群体情绪态势对研究突发事件的发展状态以及对衍生事件的预警具有重要价值。

不同类型的突发事件会引起人们不同的情绪变化。地震会导致悲伤、恐慌等负面情绪蔓延,也会出现社会对受灾人民的祝福、支持等正面情绪;公共卫生类突发事件会引起人们的气愤以及恐慌情绪;社会安全类突发事件会引起恐慌情绪以及对遇难人员的哀悼情绪。同时,在事件发生过程中,不同的因素可能会导致不同的情绪出现,比如在地震以及矿难等突发事件中出现的救援行动会让人民感到振奋,而在突发事件中政府的处理不当可能会遭到人们的质疑。

根据对不同类型的突发事件进行分析,本文建立了图1所示的面向突发事件的情绪层次模型。根据粒度不同模型分为三层,最底层将情绪细分为6类,包括高兴/支持/祝福、气愤、悲伤、恐慌、质疑以及中立;中间一层将情绪分为正面情绪、负面情绪和中立情绪;最顶层将情绪分为倾向性情绪和中立性情绪。




图1 面向突发事件的情绪层次模型




图2 主题-情绪监控预警模型

3.2 情绪监控预警模型

本文设计的情绪监控预警模型分以下几个部分:主题检测与跟踪模块、主题评论的情绪层次分类模块、时空模式分析与预警模块。图2描述了系统的框架图,每个模块的功能描述如下:

①主题检测与跟踪模块:通过数据流聚类算法进行突发事件的主题检测及跟踪^[6],得到相应的突发事件数据集,将数据提供给情绪分类器,进行情绪的层次分类;

②情绪层次分类模块:首先需要标注大量的突发事件训练集,按照图1所示的面向突发事件的情绪层次模型对数据进行标注,然后通过特征选择方法以及相应的分类算法对数据集进行训练,得到情绪分类器,其中分类器根据上文引入的情绪层次模式分为三层分类器:主客观情绪分类器、正负情绪分类器、细粒度情绪分类器,三个分类器依次对应情绪层次模型的三层。通过分类器对相关主题的数据进行情绪分类。

③时空模式分析与预警模块:根据建立的监控指标对情绪分布进行时空模式分析,通过可视化手段给用户直观的展示,并且根据预警指标及预警模式进行异常预警。

本文重点研究情绪层次分类模块,对不同分类算法以及特征选择方法在情绪分类上的性能进行比较,并对实际案例进行分析,最后对时空模式分析与预警模块进行简单分析。

4 情绪分类实验及案例分析

4.1 数据集

由于不存在公开的中文微博数据集,我们通过爬虫程序从新浪微博(<http://t.sina.com.cn>)上抓取了大量突发事件的微博数据。由于突发事件存在多种类型,为了避免实验结果过于依赖某一种类型,抓取的数据集包括了不同类型突发事件的数据。具体的,数据集包含以下几个突发事件:山西疫苗事件(公共卫生类)、地沟油事件(公共卫生类)、王家岭矿难(社会安全类)、福建南平凶杀案(社会安全类)、玉树地震(自然灾害类)、西南大旱(自然灾害类)。

首先我们需要对数据集进行情绪类别的标注,在标注过程中发现存在以下问题:①存在评论情绪表达比较模

糊,不好判断;②一条评论存在多种情绪,只标注一种情绪不合理。为了解决第一个问题,让3个人单独对评论进行标注,然后通过权衡3人的标注结果来决定最后的情绪类别,这样极大的减小了个人倾向带来的影响。为了处理第二个问题,我们将评论的情绪类别建模为情绪集合,将分类问题建模为多标签分类问题^[16]。标注后的数据集描述如表1所示。

表1 微博数据集

情绪	评论数(条)
中立	693
支持/祝福/高兴	618
气愤	572
悲伤	593
质疑	154
担心/恐慌	411

4.2 实验及结果分析

(1) 分类算法及特征集选择性能比较

本实验目的是比较三种分类算法的性能,以及比较不同的特征集之间的分类性能。分类算法采用上文介绍的三种分类算法:支持向量机、贝叶斯文本分类算法、 n 元语言模型。特征集的选择采用以下几种方式:

①全部词语

②全部词语-停用词

停用词是指那些文本中出现频率很高,但实际意义又不大的词,在传统文本分类中去掉停用词通常会提高分类性能,所以这里来检验去掉停用词是否会提高情绪分类性能。

③形容词+副词+语气词+叹词

考虑到人们在表达自己的情绪时,往往带有不同的形容词、副词、语气词以及叹词,比如“哎”“呜呜”“哈哈”等都表示了不同的情绪,所以选择这四种此性的词语作为特征集来检验情绪分类的性能。

n 元语言模型不存在选择特征集的问题,所以不参与比较。

表2 分类算法以及不同特征集的性能比较

特征集	特征数	支持向量机	贝叶斯文本分类	n 元语言模型
全部词语	8634	73.4385%	72.0579%	66%
去除停用词	6843	72.4852%	71.6963%	
形容词+副词+语气词+叹词	3123	48.5207%	49.0467%	

通过表2给出的结果可以看出,在所有的分类算法中,支持向量机、贝叶斯分类算法要明显好于 n 元语言模

型,采用所有的词语作为特征集性能最佳;而去除停用词性能并没有像传统文本分类那样得到明显的提升;出乎意

料的是形容词+副词+语气词+叹词这种组合取得的效果很不理想,通过对分类错误的评论进行分析,我们发现同一个叹词在不同场景下表示的含义是不一样的,比如“唉”这个叹词,在“唉!以后该不该带儿子去打预防针呢?”这句话里表示的是害怕,而在“唉!福建南平事件,杯具啊”表示悲伤,这说明只通过形容词+副词+语气词+叹词来判断评论的情绪是不可行的,必须要考虑不同的场景。

(2) 特征选择算法的比较

通过特征选择方法不仅可以减小特征的规模,而且可以提高分类的性能,所以对特征选择算法的选择对分类性能非常关键。本实验比较了三种特征选择方法的性能。比较结果如表2所示。




图3 特征选择方法之间的比较

从图3可以看出,IG在特征选择性能上要明显优于其他两种方法,不仅在分类性能上表现最好,而且在消除冗余特征上更具有优势。当特征数量在3000时IG的性能达到最佳,分类准确率为73.4385%,而另外两种方法当特征数量达到5000左右时,性能才达到最佳,并且分类性能只达到70%左右。这与文献[14]、文献[17]所得到的结论一致。

按照表1给出的情绪层次模型,对三层分类器的性能进行了汇总分析,得到的结果如表3所示。

表3 三层分类器分类性能

分类器	分类性能
主客观情绪分类器	90.3422%
正负面情绪分类器	84.1912%
细粒度情绪分类器	73.4385%

通过表3,不难发现随着情绪划分不断细化,分类器的性能也会逐步下降。在实际应用中,应该根据不同的需求使用不同层次的情绪分类。如果只关心正负面情绪发展的态势,可以使用正负情绪分类器对评论进行分类,这样得到的结果就会准确一些;如果要跟踪细粒度的情绪,相应的,分类器的准确性就会下降,所以用户应该在需求和准确率之间找到一个折衷。

4.3 实际案例分析

下面以王家岭矿难和山西疫苗两个突发事件进行案例研究。通过对新浪微博上关于两个事件评论的情绪态势进行分析,得到了如下所示的情绪层次曲线,通过演化曲线我们可以实时的了解到事件的发生状态以及大众对事件的情绪演化。

(1) 王家岭矿难事件

图4、图5、图6是王家岭矿难发生后,对新浪微博上出现的评论进行情绪分类后,绘制的三层情绪演化曲线,时间从2010-03-26至2010-04-13。从图4可以看出在王家岭矿难发生后,新浪微搏上主客观信息数量基本相同,但是在2010-04-05这一天,主观评论突然增多,更进一步我们通过图5发现在主观评论里面,正面评论要大于负面评论,这是因为当天救援队成功解救了多名受困矿工。




图4 王家岭事件第一层情绪分类




图5 王家岭事件第二层情绪曲线




图6 王家岭事件第三层情绪曲线

从图6可以对更细粒度的情绪进行监控,在事件发生前后几天,微博的评论混杂了不同的情绪,其中气愤、悲伤

情绪较多,而焦虑情绪比较少,但是到2010-04-05这一天,微博上出现了大量正面的评论,对救援行动给予了支持和肯定,但是不能忽视的是虽然正面情绪占绝对优势,其他的负面情绪同样也因为事件的关注度提高而有所增多,甚至出现了一些质疑的声音,质疑救援行动的真实性。随着时间的推移,人们的各种评论慢慢较少,直至消亡。

(2) 山西疫苗事件

图7、图8、图9是山西疫苗事件发生后,新浪微博上情绪的分佈情况。从图中可以看出,山西疫苗事件一经披露,各种评论便大量出现,掺杂了各种情绪,其中包括气愤、悲伤、担心等负面情绪。与王家岭矿难不同的是,因为疫苗涉及到每个人及家庭,所以担心/恐慌的情绪也十分明显。值得注意的是,在事件发生过程中出现了一些正面情绪,这实际上是对揭露事件真相的记者的支持、祝福的评论,因为本文没有区分评论的对象,所以这些评论被分类为正面情绪。




图7 山西疫苗事件第一层情绪曲线




图8 山西疫苗事件第二层情绪曲线




图9 山西疫苗事件第三层情绪曲线

从两个突发事件的情绪演化曲线来看,两个事件的评论都经历了一个高峰,但是王家岭事件是因为成功的救援行动而得到人们的关注,而山西疫苗事件是因为事件的突然曝光而得到关注,在这两个评论高峰中,大众所表现出的情绪分布是不一样的,山西疫苗负面情绪居多,王家岭事件正面情绪更加明显,在情绪监控中我们应该区分对待各种情况已达到预警的目的。

5 情绪异常预警指标与预警模式

对突发事件发生后大众评论所含的情绪的宏观态势进行实时监控的目的是为了监控可能出现的情绪异常波动,所以有必要建立一套有效的指标集进行实时的预警。

本文初步提出了一套情绪异常波动预警指标集和情绪异常模式,但对异常的分析没有涉及,这也是我们后期的工作。

5.1 情绪异常波动预警指标集

当前网络舆情预警指标^[4-5]大多以评论规模为研究对象,定义相关的预警指标,而对评论本身所含的情绪因素关注不足。为了对大众情绪进行实时的监控预警,不仅需要参考已有的指标集,而且要结合评论所包含的情绪来定义相关指标集。本文从情绪的整体分布和单一情绪两个角度定义了两类指标集。

(1) 整体情绪指标

①情绪分布度

刻画不同情绪的分布情况,公式定义如下:

$$D_t = \sum_i (N_{t,i} - E_t)^2 / it$$

其中, $N_{t,i}$ 表示 t 时刻第 i 中情绪对应的评论数量, E_t 表示 t 时刻不同类别情绪对应的评论数量的均值,使用方差来表示情绪的分布情况。

②情绪分布变化率

刻画情绪分布的变化情况,公式定义如下:

$$R = \left| \frac{D_j - D_i}{T_j - T_i} \right|$$

其中, D_i, D_j 分别表示 i, j 时刻情绪的分布度, T_i, T_j 分别表示时刻 i, j 。

(2) 单一情绪指标

①情绪热度

刻画某种情绪在所有评论中所占的比例,公式定义如下:

$$H_{t,i} = \frac{N_{t,i}}{\sum_i N_{t,i}}$$

其中, $N_{t,i}$ 表示 t 时刻第 i 中情绪对应的评论数量。

②情绪拐点

刻画某种情绪的变化情况,公式定义如下:

$$G_k = \frac{N_{k,j} - N_{k,i}}{T_j - T_i}$$

其中, $N_{k,i}, N_{k,j}$ 表示时刻 i, j 第 k 中情绪对应的评论数量, T_i, T_j 分别表示时刻 i, j .

5.2 情绪异常模式

结合预警指标集, 本文从时间、空间两个维度定义了几种情绪异常模式。

(1) 时间维度

①情绪分布异常波动

当情绪分布变化率上超过一定阈值时, 说明整体情绪异常波动, 应该进行预警。

②负面情绪拐点

当某一种负面情绪的拐点超过一定阈值时, 定义为情绪拐点, 这时应该进行预警。

③负面情绪爆发

当某一种负面情绪在热度上超过一个指定的峰值时, 这时应该进行预警。

(2) 空间维度

④空间分布异常波动

从空间维度监控情绪分布, 如果出现情绪过度集中于一个区域, 或者情绪快速蔓延到更大的范围时, 应该进行预警。

6 结论

本文对突发事件的群体情绪监控预警进行了初步研究, 提出了面向突发事件的情绪层次模型以及情绪监控预警模型。通过三种机器学习方法以及三种特征选择方法对微博的情绪分类进行了分析, 结果表明支持向量机和 IG 特征选择方法结合对微博的情绪分类性能最优。进而对两个实际的案例进行了分析, 通过分析了解到引入评论的情绪因素对突发事件网络舆情的预警指标及预警模型进行了探索。

本文只是对情绪监控预警进行了初步的探讨, 所以以下一些问题需要继续研究: ①按照评论对象进行情绪的分析, 这样得到的情绪会更加有针对性, 对于决策者也更有实际价值, 通过给出自动摘要的形式, 使用者可以很方便的了解到大众对于不同的对象的情绪分布情况; ②研究不同因素导致的情绪演化模式问题, 突发事件发生后, 不同因素会造成大众不同的情绪变化, 不如政府的措施、突发事件的破坏性等。③情绪异常的实时监控预警, 本文只是提出了情绪异常指标集合异常模式, 对于不同的突发事件, 怎么来构建预警模型是一个值得探讨的问题。这些问题也是我们下一步的工作重点。

参考文献:

- [1] 曾大军, 王飞跃, 曹志东. 开源信息在突发事件应急管理中的应用[J]. 科技导报, 2008; 27~33.
- [2] 王飞跃. 万维社会媒体在防灾应急中的作用[J]. 科技导报, 2008, 26(10): 30~31.
- [3] Li M L, Chen A. A web mining based measurement and monitoring model of urban mass panic in emergency management [C]//Fifth international conference on fuzzy systems and knowledge discovery, 2008; 366~370.
- [4] 戴媛, 姚飞. 基于网络舆情安全的信息挖掘及评估指标体系研究[J]. 情报理论与实际, 2008, 6; 873~876.
- [5] 谢海光, 陈中润. 互联网内容及舆情深度分析模式[J]. 中国青年政治学院学报, 2006, 3; 95~100.
- [6] Aggarwal C C, Han J W, Wang J Y, Yu P S. A framework for clustering evolving data streams [C]//Proceedings of the 29th VLDB Conference, Berlin, Germany, 2003.
- [7] Vapnik V N. The nature of statistical learning theory[M]. New York: Springer, 1995.
- [8] Joachims T. Text categorization with support vector machines: Learning with many relevant features [C]//Proceeding of 10th Eureka Conference on Machine Learning, 1998; 137~142.
- [9] Fan R E, et al. LIBLINEAR: A library for large linear classification [J]. Journal of Machine Learning Research, 2008; 1871~1874.
- [10] Domingos P, Pazzani M J. On the optimality of the simple bayesian classifier under zero-one loss [J]. Machine Learning, 1997; 103~130.
- [11] McCallum A, Nigam K. A comparison of event models for naive bayes text classification [C]//AAAI-98 workshop on learning for text categorization, 1998; 41~48.
- [12] Ye Q, Zhang Z Q, Law R. Sentiment classification of online reviews to travel destinations by supervised machine learning approaches [J]. Expert Systems with Applications, 2009; 6527~6535.
- [13] Carpenter B. Scaling high-order character language models to gigabytes [C]//Proceedings of the 2005 association for computational linguistics software workshop, 2005; 1~14.
- [14] Yang Y, Pedersen J O. A comparative study on feature selection in text categorization[J]. ICML, 1997; 412~420.
- [15] 单松巍, 冯是聪, 李晓明. 几种典型特征选取方法在中文网页分类上的效果比较[J]. 计算机工程与应用, 2003; 146~148.

[16]

Tsoumakas G, Katakis I. Multi-label classification: An overview [J]. International Journal of Data Warehousing and Mining, 2005; 1~13.

[17]

Tan S B, Zhang J. An empirical study of sentiment analysis for chinese documents [J]. Expert Systems with Applications, 2008; 2622~2629.

Public Emotion Monitoring and Surveillance in Emergencies

LIU Zhi-ming, LIU Lu

(School of Economics and Management, Beihang University, Beijing 100191, China)

Abstract: The public emotions in emergencies may lead to other public events, so it is necessary to monitor and track the evolution of the public emotions in time. This paper studies the evolution of the public emotions during the emergencies. Firstly, we construct a hierarchical emotion model for emergencies and an emotion monitoring surveillance model. Secondly, we use three machine learning algorithms and three kinds of feature selection methods to study the emotion classification for Chinese microblog about the emergencies. The experimental results show the performance of SVM and IG feature selection is best, and the accuracy of the classification is fit for need, then the paper discussed two real cases and analyses the evolution of emotions. Finally we define some surveillance indexes and surveillance patterns for emergency early warning.

Key words: Emotion Monitoring; Emotion Monitoring Surveillance Model; Machine Learning; Surveillance Index